

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

ZÁKLADY KOLABORÁCIE ROBOTOV
BAKALÁRSKA PRÁCA

2026
MARTIN ČERMÁK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

ZÁKLADY KOLABORÁCIE ROBOTOV
BAKALÁRSKA PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: Ing. Branislav Zigo
Konzultant: RNDr. Kristína Malinovská, PhD

Bratislava, 2026
Martin Čermák



ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Martin Čermák
Študijný program: aplikovaná informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: bakalárska
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Základy kolaborácie robotov
Fundamentals of robot collaboration

Anotácia: Kognitívna robotika sa zaoberá vytváraním inteligentných, často humanoidných robotov, ktoré sa učia skúsenosťou podobne ako deti. Veľmi typickou úlohou pre takéto roboty je manipulácia s objektmi v blízkosti robota, prípadne aj v kooperácii s človekom. Pre učenie sa rôznych zručností sa v tejto doméne zväčša používa strojové učenie (hlavne umelé neurónové siete), ktoré vyžaduje veľké množstvá dát a/alebo ich sústavné získavanie v simulátore. Pre kolaboratívnu úlohu, napríklad stavanie veže z kociek, musí robot vedieť rozpoznať v akom stave sa úloha nachádza a hlavne ak sa strieda v stavaní s človekom aj to, čo sa chystá človek robiť a čo má následne urobiť robot, čiže vybrať nejakú akciu pre nejaký objekt.

Cieľ: Cieľom práce je v rámci teoretickej časti spracovať a vyhodnotiť dostupnú literatúru o rozpoznávaní akcií a možnostiach interakcie v kognitívnej robotike, interakcii medzi robotmi a v kolaboratívnom scenári. Na základe týchto poznatkov navrhnete a implementujete prototyp softvéru pre humanoidného robota NICO, ktorý umožní autonómnú lokalizáciu objektov v 3D priestore. Výsledkom práce je realizácia kolaboratívneho scenára, v ktorom NICO identifikuje polohu cieľového objektu držaného ramenom Niryo Ned a následne na túto informáciu reaguje vykonaním pohybu smerom k objektu.

Literatúra: [1] Kerzel, M. et al. "NICO - Neuro-inspired companion: A developmental humanoid robot platform for multimodal interaction," 26th IEEE International Symposium on Robot and Human Interactive Communication (RO-MAN), 2017, pp. 113-120.
[2] Gavura J., Vavrecka M., Farkaš I., Gäde C.: Robotic Calibration Based on Haptic Feedback Improves Sim-to-Real Transfer. In International Conference on Artificial Neural Networks (ICANN), Springer Nature. 2025.
[3] Skoviera, R., Stepanova, K., Tesar, M., Sejnova, G., Sedlar, J., Vavrecka, M., Babuska, R. and Sivic, J., 2019. Teaching robots to imitate a human with no on-teacher sensors. What are the key challenges?. arXiv preprint arXiv:1901.08335.

Vedúci: Ing. Branislav Zigo
Konzultant: RNDr. Kristína Malinovská, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

Dátum zadania: 05.05.2026

Dátum schválenia: 05.05.2026

doc. RNDr. Damas Gruska, PhD.
garant študijného programu

.....
š t u d e n t

.....
v e d ú c i p r á c e

Čestné vyhlásenie: Čestne vyhlasujem, že celú bakalársku prácu na tému „Základy kolaborácie robotov“, vrátane všetkých jej príloh a obrázkov, som vypracoval samostatne, a to s použitím literatúry uvedenej v priloženom zozname.

Pri príprave tejto práce boli tiež použité nástroje umelej inteligencie Google Gemini za účelom stylistickej a gramatickej úpravy textu. Nástroje umelej inteligencie som použil v súlade s príslušnými právnymi predpismi, akademickými právami a slobodami, etickými a morálnymi zásadami za súčasného dodržania akademickej integrity. Som si vedomý, že plne zodpovedám za správnosť výsledného textu.

PodĎakovanie: Rád by som sa poďakoval svojmu školiteľovi, Ing. Branislavovi Zigovi, za jeho pomoc a ochotu, najmä pri formovaní praktickej časti, ako aj pri tvorbe celej tejto práce. Moja vďaka patrí rovnako aj konzultantke, RNDr. Kristíne Malinovskej, PhD., za jej trpezlivosť a pomoc počas celého priebehu práce.

V neposlednom rade patrí veľké poďakovanie mojej rodine a priateľom za ich nekonečnú podporu a povzbudenie nielen počas písania tejto práce, ale aj počas celého môjho štúdia na univerzite.

Abstrakt

Cieľom práce bolo prepojiť humanoidného robota NICO a kolaboratívne rameno Niryo Ned do autonómneho integrovaného celku, v ktorom NICO dokáže vizuálne lokalizovať dynamicky sa pohybujúci objekt v 3D priestore a následne ho fyzicky dosiahnuť. Predpokladali sme, že spojením stereoskopického videnia s korekciou extrémneho skreslenia širokouhlých šošoviek, výpočtom inverznej kinematiky pomocou nelineárnej optimalizácie L-BFGS-B a pridaním externého meracieho obvodu s mikrokontrolérom Arduino pre hmatovú spätnú väzbu dosiahneme bezpečnú a presnú interakciu. Pri testovaní na vzorke 50 autonómnych iterácií sme zistili, že systém lokalizoval objekt s 86% úspešnosťou a vďaka adaptívnemu ladeniu cieľových súradníc dokázal kompenzovať optické nepresnosti, čím dosiahol 100% úspešnosť fyzického kontaktu pri všetkých priestorovo dosiahnuteľných bodoch. Výsledkom riešenia danej problematiky je robustná softvérová a hardvérová architektúra s celkovou úspešnosťou experimentu 74%, ktorá efektívne prekonáva obmedzenia kamerového hardvéru.

Kľúčové slová: kognitívna robotika, stereoskopické videnie, inverzná kinematika, kolaborácia robotov

Abstract

The aim of the thesis was to connect the humanoid robot NICO and the Niryo Ned collaborative arm into an autonomous integrated system, where NICO can visually localize a dynamically moving object in 3D space and subsequently physically reach it. We hypothesized that by combining stereoscopic vision with severe wide-angle lens distortion correction, calculating inverse kinematics using L-BFGS-B nonlinear optimization, and adding an external measuring circuit with an Arduino microcontroller for haptic feedback, we would achieve safe and precise interaction. During testing on a sample of 50 autonomous iterations, we found that the system localized the object with an 86% success rate, and thanks to adaptive target coordinate tuning, it successfully compensated for optical inaccuracies to achieve a 100% physical contact success rate for all spatially reachable points. The result of solving the given issue is a robust software and hardware architecture with an overall experiment success rate of 74%, which effectively overcomes the limitations of camera hardware.

Keywords: cognitive robotics, stereoscopic vision, inverse kinematics, robot collaboration

Obsah

1	Prehľad technológií a súčasných prístupov v robotike	3
1.1	Kognitívna robotika	3
1.1.1	Kolaborácia v kognitívnej robotike	3
1.2	Metódy vnímania v robotike	4
1.2.1	Aktívne metódy snímania hĺbky	4
1.2.2	Pasívne metódy snímania hĺbky	5
2	Stereo videnie	7
2.1	Geometrický model stereo systému	7
2.2	Kalibrácia stereo kamier	8
2.3	Rektifikácia obrazu	9
2.4	Mapa disparity a výpočet hĺbky	10
2.5	Presnosť a zdroje chýb	10
3	Detekcia a lokalizácia objektov	13
3.1	Farebná segmentácia	13
3.2	Rozpoznávanie objektu podľa tvaru	14
3.2.1	Detekcia a analýza kontúr	14
3.2.2	Houghova transformácia pre kružnice	14
3.3	Alternatívne metódy detekcie objektov	15
3.4	Lokalizácia v 3D priestore	15
4	Inverzná kinematika	17
4.1	Definícia a princíp	17
4.2	Analytické vs. numerické metódy	18
4.2.1	Analytické metódy	19
4.2.2	Numerické metódy	19
4.3	Aplikácia v humanoidných robotoch	20
5	Robotické platformy	23
5.1	Robot NICO	23

5.1.1	Vizuálny senzorický systém	23
5.1.2	Kinematická štruktúra	24
5.2	Robotické rameno Niryo Ned	24
5.2.1	Hardvérová a softvérová architektúra	24
5.2.2	Kinematické vlastnosti a pracovný priestor	24
5.3	Koordinácia rozdielnych platforiem	25
5.3.1	Spoločný komunikačný rámec	25
5.3.2	Transformácia súradnicových systémov	25
6	Cieľ práce	27
7	Metodika práce a implementácia systému	29
7.1	Charakteristika laboratórneho pracoviska	29
7.2	Spracovanie obrazu a priestorová lokalizácia	29
7.2.1	Stereoskopická kalibrácia	29
7.2.2	Detekcia objektu na základe tvaru a jasu	30
7.2.3	Triangulácia	31
7.3	Riadenie pohybu ramena Niryo Ned	31
7.4	Inverzná kinematika a pohyb robota NICO	32
7.4.1	Geometrická transformácia a počiatočný odhad	32
7.4.2	Dopredná kinematika	33
7.4.3	Nelineárna optimalizácia a penalizačná funkcia	33
7.4.4	Fyzická realizácia pohybu	33
7.5	Hardvérová implementácia a detekcia fyzického kontaktu	34
7.5.1	Fyzické zapojenie obvodu	34
7.5.2	Spracovanie signálu v mikrokontroléri	35
7.5.3	Spracovanie a validácia kontaktu	35
7.6	Synchronizácia procesov	36
7.6.1	Inicializačná fáza	36
7.6.2	Logika hlavného cyklu	36
7.7	Metodika testovania	37
8	Výsledky práce a diskusia	39
8.1	Vyhodnotenie vizuálnej detekcie a triangulácie	39
8.2	Inverzná kinematika a ochrana pracovného priestoru	40
8.3	Úspešnosť fyzického kontaktu a adaptívne ladenie	40
8.4	Zhodnotenie experimentu	41
	Literatúra	43

Príloha A	45
Príloha B	47

Zoznam obrázkov

Zoznam tabuliek

8.1 Úspešnosť fyzického kontaktu v závislosti od počtu iteračných korekcií .	40
--	----

Úvod

Kognitívna robotika spája viacero vedeckých a technických odborov do jedného komplexného celku. Využíva pri tom poznatky z klasickej robotiky, umelej inteligencie, neurónových sietí a kognitívnych vied s cieľom vytvoriť inteligentné systémy schopné samostatného učenia, vnímania a adaptívneho rozhodovania. Na rozdiel od klasických robotov, ktoré vykonávajú len vopred naprogramované úlohy, sa kognitívne roboty snažia porozumieť svetu okolo seba a adekvátne naň reagovať. Jednou z hlavných výziev v tejto oblasti je schopnosť robota rozpoznať a porozumieť ľudským akciám a úmyslom tak, aby dokázal efektívne spolupracovať s človekom na spoločných úlohách. Samotné rozpoznávanie akcií umožňuje robotovi predvídať ďalšie kroky partnera, včas sa pripraviť a dosiahnuť lepšiu formu interakcie. dosiahnuť vyššiu formu plynulej interakcie.

Táto bakalárska práca sa zameriava na praktickú implementáciu kolaboratívneho scenára medzi dvoma odlišnými robotickými platformami, a to humanoidným robotom NICO a robotickým ramenom Niryo Ned. Hlavným cieľom je navrhnuť a realizovať systém, ktorý umožní robotovi NICO autonómne lokalizovať objekt v trojrozmernom priestore bez pomoci externých vizualných bodov či pevne definovaných pracovných plôch. Na rozdiel od riešení v statických podmienkach sa táto práca zaoberá dynamickým umiestnením objektu, s ktorým manipuluje robotické rameno v priestore. Tento scenár si vyžaduje precízne spracovanie obrazu a presné riadenie pohybu, čím sa približujeme k reálnym spoluprácam medzi robotmi.

Jedným z kľúčových prvkov takejto interakcie je vizuálne vnímanie, ktoré robotovi poskytuje informácie o stave a pozícii objektov v jeho okolí. Táto bakalárska práca sa zameriava na využitie stereo videnia na humanoidnej platforme NICO. Stereo videnie umožňuje robotovi získavať priestorovú informáciu aj o hĺbke, čo je nevyhnutné pre presnú lokalizáciu objektov, ktoré nie sú viazané na fixnú pracovnú plochu. Praktickým cieľom práce je realizácia kolaboratívneho scenára, v ktorom robot NICO lokalizuje objekt manipulovaný iným robotickým ramenom a vykoná k nemu cielený pohyb.

Práca je rozdelená do ôsmich hlavných kapitol. Prvá až šiesta kapitola sa venujú teoretickému úvodu do problematiky kognitívnej robotiky, stereoskopického videnia, spracovania obrazu a inverznej kinematiky. Siedma kapitola popisuje navrhnutú metódu, softvérovú a hardvérovú implementáciu nášho experimentu. Ôsma kapitola prezentuje reálne výsledky dosiahnuté počas autonómneho experimentálneho testovania,

analyzuje úspešnosť jednotlivých modulov a zhŕňa priebeh celeho experimentu.

Kapitola 1

Prehľad technológií a súčasných prístupov v robotike

1.1 Kognitívna robotika

Kognitívna robotika predstavuje moderný prístup k vývoju inteligentných systémov, ktorý sa snaží prekonať limity klasickej priemyselnej robotiky. Štandardné priemyselné robotické systémy sú navrhnuté na precízne vykonávanie vopred definovaných úloh v prísne štruktúrovanom prostredí. Kognitívna robotika sa inšpiruje biologickými systémami, kognitívnou vedou a umelou inteligenciou [15], pričom jej primárnym cieľom je vytvoriť roboty, ktoré sú schopné sa autonómne učiť, vnímať a adaptovať na dynamické podmienky [1].

Kognitívne systémy fungujú na princípe tzv. cyklu vnímania a akcie (perception-action cycle) [19]. V tomto uzavretom procese robot neustále spracováva senzorické vstupy zo svojho okolia, interpretuje si ich do svojej reality a na základe svojich cieľov a naučených skúseností adekvátne vykonáva motorické príkazy [15]. Tento prístup je kľúčový pre platformy ako napríklad NICO (Neuro-inspired COmpanion), ktorý bol vyvinutý ako multimodálna výskumná platforma pre štúdium neurónovo-inšpirovaných modelov správania a interakcie [10].

1.1.1 Kolaborácia v kognitívnej robotike

V rámci kognitívnej robotiky už kolaborácia neznamena len bežnú koexistenciu robota a človeka v jednom priestore, ale začíname hovoriť o aktívnej spolupráci na plnení spoločných úloh. Takáto interakcia si vyžaduje, aby robot vedel predpovedať úmysly svojho partnera, či už ide o človeka alebo iného robota, akým je v kontexte tejto práce rameno Niryo Ned [14].

Medzi najdôležitejšie výzvy, ktoré kognitívna robotika rieši, patria:

- **Presná lokalizácia objektov v priestore** – Schopnosť presne určiť polohu objektov bez potreby externých vizuálnych značiek. Takáto forma lokalizácie sa približuje k prirodzenému ľudskému vnímaniu [1].
- **Predvídanie akcií partnera** – Schopnosť robota rozpoznať pohyb a hlavne včas naň reagovať. Táto vlastnosť je podmienkou najmä pre plynulú a neprerušovanú spoluprácu [14].
- **Koordinácia rozdielnych systémov** – Jedným problémom je zosúladiť pohyby dvoch robotov, ale je problém iným zosúladiť pohyby dvoch, či viacerých odlišných platforiem. Rôzne platformy majú rozdielne vlastnosti, hardvérové zloženie, či riadiace algoritmy [15].
- **Učenie a nadobúdanie znalostí** – Základným aspektom kognitívneho systému je schopnosť postupného učenia sa o svojom okolí prostredníctvom aktívnej interakcie. Robot nie je obmedzený pevne danou databázou vnemov, ale v priebehu času si buduje vlastnú databázu znalostí o objektoch, prostredí a spoluaktéroch. Tento proces mu umožňuje porozumieť štruktúre prostredia a prispôbiť svoje správanie aj v nových, vopred nenaprogramovaných situáciách.[10, 1].

1.2 Metódy vnímania v robotike

Vizuálne vnímanie je hlavným zdrojom informácií pre väčšinu kognitívnych systémov. Interpretácia svojho okolia, ktorá je pre človeka prirodzená, predstavuje pre robotické systémy komplexnú výpočtovú úlohu. Ide o proces, pri ktorom si z vizuálnych dát odvodzujú konkrétnu informáciu, ktorú v daný moment potrebujú.

Štandardná digitálna kamera zachytáva svet prostredníctvom perspektívnej projekcie, pri ktorej sa trojrozmerný priestor mapuje do dvojrozmernej roviny. Pri tomto procese dochádza k strate informácie o hĺbke [9]. Aby robot dokázal efektívne operovať v 3D priestore, musí tento chýbajúci rozmer spätne zrekonštruovať. Súčasná robotika a počítačové videnie rozlišujú dva základné prístupy k riešeniu tohto problému: aktívne a pasívne metódy snímania.

1.2.1 Aktívne metódy snímania hĺbky

Aktívne senzory sa vyznačujú tým, že do prostredia emitujú vlastný signál, často vo forme infračerveného svetla alebo laserového lúča, a na základe jeho interakcie s povrchmi objektov merajú vzdialenosť. Tieto systémy sú v modernej robotike veľmi populárne vďaka svojej rýchlosti a schopnosti pracovať aj v prostrediach s nízkym kontrastom.

Senzory na báze štruktúrovaného svetla premietajú do prostredia známy svetelný vzor (napríklad mriežku). Deformácia tohto vzoru na povrchu objektov je následne snímaná kamerou a matematicky analyzovaná na výpočet hĺbky každého bodu [20].

Time-of-Flight (ToF) systémy sú senzory merajúce čas, ktorý potrebuje svetelný lúč na cestu k objektu a späť k snímaču. Umožňujú generovať hĺbkové mapy v reálnom čase s vysokou frekvenciou, čo je výhodné pre rýchlo sa pohybujúce systémy [15].

Hoci sú aktívne metódy vysoko presné a rýchle, často si však vyžadujú špecifické svetelné podmienky. Pri priamom slnečnom svetle alebo na vysoko reflexných povrchoch môžu nepresne počítat vzdialenosti, či úplne zlyhávať. V prípade viacerých robotických systémov pracujúcich v rovnakom priestore môže dochádzať k vzájomnej interferencii emitovaných signálov.

1.2.2 Pasívne metódy snímania hĺbky

Pasívne metódy sa spoliehajú na spracovanie existujúceho svetla dopadajúceho do objektívu snímača. Nevyžarujú do priestoru žiadnu vlastnú energiu, čo z nich robí systémy energeticky efektívnejšie a univerzálnejšie najmä v prostrediach s vysokým okolitým žiarením [15]. Tento prístup je však výrazne náročnejší na algoritmy spracovania dát. Snaží sa extrahovať trojrozmerné informácie z dvojrozmerného obrazu [9, 6].

Najzákladnejšou formou pasívneho vnímania je monokulárne videnie, ktoré využíva vstup z jedinej kamery. Odhad hĺbky v takomto systéme nie je priamy [9], ale musí byť založený na kontextuálnych nápovedách, ako sú:

- **Relatívna veľkosť a známa mierka** – Tento princíp predpokladá, že robot má dáta o reálnych rozmeroch snímaného objektu. Ak systém identifikuje známy objekt, tak na základe pomeru medzi jeho známou fyzickou veľkosťou a veľkosťou jeho obrazu, ktorý je už meraný v pixeloch, dokáže matematicky odhadnúť jeho vzdialenosť [6].
- **Lineárna perspektíva** – Využíva geometrické vlastnosti prostredia na odhad hĺbky z obrazu. Rovnobežné línie v trojrozmernom priestore, ako napríklad hrany stola alebo rohy simulovaného priestoru, sa pri premietnutí na 2D obraz opticky zbiehajú do jedného bodu v diaľke, tzv. úbežného bodu. Dôležitú úlohu pri odhade hĺbky zohráva aj textúra povrchu. S narastajúcou vzdialenosťou sa textúra javí hustejšia a menej detailná, pričom systém dokáže z týchto zmien odvodiť nielen vzdialenosť, ale aj samotný sklon pozorovaných plôch [9].
- **Distribúcia jasu a tieňovanie** – Dopadajúce svetlo na povrch objektu vytvára tieň, čo umožňuje kognitívnemu systému lepšie pochopiť jeho trojrozmerný tvar a zakrivenie povrchu [6].

- **Vzájomné prekrývanie** – Ak jeden objekt čiastočne zakrýva iný, systém dokáže logicky určiť ich relatívne poradie v priestore. Táto vlastnosť predstavuje základnú formu hĺbkovej diskriminácie [6].

Z matematického hľadiska je monokulárna rekonštrukcia hĺbkoy definovaná ako podurčený problém, pretože k jednej 2D projekcii existuje teoreticky nekonečné množstvo prípustných 3D konfigurácií, ktoré by ju mohli vygenerovať [9]. Práve táto neurčitost' predstavuje jednu z najväčších výziev pri učení robotov videním.

Neurčitost' monokulárneho videnia zdôrazňuje dôležitosť robustnej kalibrácie a kognitívnych mechanizmov. V súčasnosti sa výskum zameriava na zlepšenie presnosti týchto systémov pomocou multimodálnej spätnej väzby. Napríklad Gavura a kol. demonštrujú, že integrácia haptickej spätnej väzby do procesu kalibrácie dokáže výrazne znížiť chyby pri prenose vizuálnych informácií zo simulácie do reality [7]. Z tohto dôvodu sa v kognitívnej robotike, kde je prioritou plynulá spolupráca, monokulárny prístup často nahradzuje binokulárnym videním, ktoré využíva aj platforma NICO [10].

Kapitola 2

Stereo videnie

Nedostatky monokulárneho videnia a jeho fundamentálna matematická neurčitost sú v biologických systémoch prekonávané využitím binokulárneho videnia [1, 19]. Kognitívna robotika tento princíp priamo preberá a využíva dve kamery namiesto jednej. Dve kamery umožňujú snímať rovnakú scénu z rôznych, no blízkych perspektív. Tento prístup nevyžaduje emitovanie vlastného signálu do prostredia, vďaka čomu patrí medzi plne pasívne metódy snímania [15].

Základným výpočtovým krokom pri rekonštrukcii hĺbky pomocou dvoch kamier je riešenie takzvaného problému korešpondencie. Tento proces spočíva v hľadaní páriacich sa bodov. Algoritmus musí v ľavom a pravom obraze identifikovať tie pixely, ktoré sú priemetom toho istého fyzického bodu v reálnom 3D prostredí. Pretože sa kamery nachádzajú na rôznych pozíciách (sú horizontálne posunuté o nejakú dĺžku), ten istý bod scény sa premietne na mierne odlišné súradnice na obrazoch oboch kamier [9]. Práve vďaka tejto vlastnosti sme schopní následne odvodiť hĺbku, v ktorej sa reálny bod nachádza.

Stereo videnie spája výhody pasívneho snímania (funkčnosť v bežných svetelných podmienkach bez interferencií) s dostatočnou presnosťou pre manipuláciu s objektmi. Správne nakalibrovaný stereo systém tak poskytuje robotickým platformám fundamentálne priestorové vnímanie, na ktorom je možné stavať zložitejšie kognitívne a kolaboratívne úlohy.

2.1 Geometrický model stereo systému

Pre matematický popis transformácie trojrozmerného sveta do dvojrozmerných digitálnych obrazov sa v počítačovom videní štandardne využíva pinhole camera model. V tomto modeli prechádzajú všetky svetelné lúče cez jeden stredový bod, nazývaný optický stred kamery, a následne dopadajú na obrazovú rovinu. Základným parametrom tohto modelu je fokálna (ohnisková) vzdialenosť (f), ktorá definuje fyzickú vzdia-

lenosť medzi optickým stredom šošovky a rovinou obrazového snímača [9]. V kontexte digitálneho spracovania sa táto vzdialenosť často rozdeľuje na zložky f_x a f_y vyjadrené v pixeloch. Tento prepočet je závislý od reálnej fyzickej šírky a výšky jednotlivých pixelov na obrazovom snímači. V prípade, že pixely snímača nie sú dokonale štvorcové, hodnoty ohniskovej vzdialenosti na osiach x a y sa budú mierne líšiť.

Stereoskopický systém vzniká pridaním druhej kamery, ktorá sníma totožnú scénu z odlišného pohľadu. Kľúčovým konštrukčným parametrom takéhoto systému je základňa (baseline B). Predstavuje fyzickú vzdialenosť medzi optickými stredmi ľavej a pravej kamery. Veľkosť základne priamo ovplyvňuje schopnosť systému vnímať hĺbku. Širšia základňa umožňuje presnejší odhad vzdialenosti pre vzdialené objekty. Zároveň však zväčšuje oblasť v tesnej blízkosti kamier, ktorú nedokážu zachytiť oba snímače súčasne, čo vytvára slepé uhly [9].

Po zosnímaní objektu oboma kamerami je pre výpočet jeho vzdialenosti ďalším krokom identifikovať totožné body v oboch obrazoch. Na zjednodušenie tohto výpočtového náročného procesu sa využíva epipolárna geometria, ktorá presne popisuje vnútorné projektívne vzťahy medzi dvoma pohľadmi na rovnakú scénu [9]. 3D bod v priestore a optické stredy oboch kamier spoločne definujú epipolárnu rovinu. Priesečník základne B s obrazovými rovinami sa nazýva epipól, pričom priemet epipolárnej roviny do samotných obrazov vytvára epipolárnu líniu [9].

Najväčším prínosom tohto modelu je takzvané epipolárne obmedzenie. To matematicky zaručuje, že ak poznáme presnú polohu priemetu sledovaného bodu v ľavom obraze, jeho korešpondujúci priemet v pravom obraze sa nemôže nachádzať na ľubovoľnom mieste. Musí ležať výhradne na jeho príslušnej epipolárnej línii [9]. Vďaka tomuto pravidlu sa problém hľadania korešpondencie redukuje z výpočtového náročného prehľadávania celej 2D plochy obrazu na hľadanie pozdĺž 1D priamky.

2.2 Kalibrácia stereo kamier

V reálnych robotických aplikáciách sú snímané obrazy skoro vždy zaťažené optickým skreslením šošoviek a drobnými nepresnosťami pri mechanickom upevnení snímačov [6]. Proces, ktorým sa tieto fyzikálne odchýlky identifikujú a matematicky korigujú, sa nazýva kalibrácia kamery. Pre správne fungovanie stereo videnia je tak nevyhnutné určiť dva základné typy parametrov: intrinsické a extrinsické [9].

Intrinsické (vnútorné) parametre definujú optické vlastnosti samotnej kamery. Patria sem ohniskové vzdialenosti (f_x, f_y), súradnice optického stredy snímača (c_x, c_y) a koeficienty radiálneho a tangenciálneho skreslenia [6]. Radiálne skreslenie (tzv. efekt rybieho oka) spôsobuje, že rovné čiary sa v obraze javia ako zakrivené, čo by výrazne skreslilo princípy epipolárnej geometrie. Tieto parametre sa zoskupujú do takzvanej

matice kamery a zisťujú sa nezávisle pre ľavú aj pravú kameru [9].

Extrinsické (vonkajšie) parametre matematicky popisujú vzájomný priestorový vzťah medzi ľavou a pravou kamerou. Sú reprezentované maticou rotácie (R) a vektorom translácie (T). Vektor translácie priamo vyjadruje presnú fyzickú vzdialenosť medzi optickými stredmi oboch kamier v trojrozmernom priestore, teda skutočnú dĺžku základne, ktorú systém potrebuje pre výpočet hĺbky [9].

Štandardným a najviac využívaným prístupom pre získanie týchto parametrov je šachovnicová metóda [6]. Tento proces využíva kalibračný vzor v podobe čierneho-bielej šachovnice so známymi fyzickými rozmermi štvorcov. Robotický systém sníma túto šachovnicu oboma kamerami súčasne z rôznych uhlov a vzdialeností. Algoritmy počítačového videnia následne v obrazoch detegujú vnútorné rohy šachovnice. Systém pozná reálnu geometriu vzoru (rohy sú v dokonalej rovine, štvorce majú stranu dĺžky 50 mm), čo mu umožňuje pomocou optimalizačných metód spätne vypočítať skreslenie a polohu kamier, ktoré spôsobili konkrétny priemet každého rohu do 2D obrazu [6, 9].

V softvérovom prostredí, typicky s využitím knižnice OpenCV, je tento matematický aparát implementovaný vo funkcii stereoCalibrate. Táto funkcia prijíma ako vstup zoznam detegovaných 2D bodov z oboch kamier spolu s ich známymi 3D súradnicami na šachovnici, a jej výstupom sú optimalizované intrinsické a extrinsické matice. Na tieto výsledky následne nadväzuje funkcia stereoRectify, ktorá vypočíta transformačné matice potrebné pre finálne zarovnanie obrazov.

2.3 Rektifikácia obrazu

Úspešná kalibrácia a výpočet transformačných matíc predstavujú teoretický základ, ktorý je následne potrebné aplikovať na samotné snímky z kamery. Epipolárna geometria teoreticky redukuje hľadanie korešpondencií na 1D priamku. V pôvodných obrazoch z kamier môžu tieto epipolárne línie smerovať pod rôznymi šikmými uhlami [9]. Prehľadávanie šikmých línií v pamäti počítača je algoritmicky aj výpočtovo veľmi neefektívne a spomaľovalo by reakcie robota. Tento problém rieši práve proces nazývaný rektifikácia obrazu.

Algoritmus využitím extrinsických a intrinsických transformačných matíc, získaných počas kalibrácie, softvérovo narovná obrazy do jednej spoločnej roviny. Matematicky to znamená, že sa pôvodné obrazy pretransformujú do podoby, akoby boli nasnímané dvoma paralelnými kamerami s identickými vnútornými parametrami [9].

Vďaka rektifikácii sa všetky epipolárne línie stanú dokonale horizontálnymi a paralelnými s osou X kamery [9]. V praxi to prináša radikálne zníženie výpočtovej náročnosti následných algoritmov. Ak hľadáme špecifický pixel nachádzajúci sa v ľavom rektifikovanom obraze na riadku s indexom y , jeho korešpondujúci bod v pravom ob-

raze sa musí nachádzať presne na tom istom riadku y . Vyhľadávanie sa tak redukuje na triviálny posun iba po horizontálnej osi x [6].

2.4 Mapa disparity a výpočet hĺbky

Rektifikácia obrazov pripraví systém na samotný výpočet vzdialenosti, kde je prvým krokom výpočet mapy disparity. Disparita d predstavuje rozdiel v súradniciach osi x pre ten istý bod v ľavom (u_L) a pravom (u_R) rektifikovanom obraze. Matematicky to vieme vyjadriť ako $d = u_L - u_R$ [9].

Na hľadanie páriacich sa bodov sa v počítačovom videní využívajú algoritmy založené na princípe porovnávania blokov (Block Matching). Ide o porovnávanie malých výrezov pixelov z ľavého obrazu s rovnako veľkými výrezmi v pravom obraze a hľadanie ich najväčšej vizuálnej zhody. V modernej robotike sa preferuje pokročilejší a robustnejší prístup Semi-Global Block Matching (SGBM). Tento algoritmus okrem porovnávania lokálnych blokov zároveň penalizuje neprirodzené skoky v hĺbke a optimalizuje plynulosť disparity naprieč celým obrazom. Tým výrazne redukuje šum a chybné merania na jednoliatych povrchoch bez výraznej textúry [6].

Po určení disparity pre všetky pixely obrazu nasleduje výpočet samotnej hĺbky. Využíva sa pri tom geometrický vzťah triangulácie, ktorý prepája disparitu d , ohniskovú vzdialenosť f a fyzickú dĺžku základne B [9]:

$$Z = \frac{f \cdot B}{d} \quad (2.1)$$

Hĺbka Z je nepriamo úmerná disparite. Čím je objekt k robotovi bližšie, tým väčší je posun jeho priemetu medzi kamerami, čo predstavuje vysokú disparitu. Naopak, pri veľmi vzdialených objektoch sa rozdiely strácajú a disparita sa blíži k nule [9]. Výstupom tohto výpočtového reťazca je matica, inak nazývaná aj hĺbková mapa, v ktorej hodnoty predstavujú fyzickú vzdialenosť bodov od robota. Tieto priestorové dáta sú vstupom pre systémy 3D lokalizácie a následnú manipuláciu objektov pomocou inverznej kinematiky [10, 17].

2.5 Presnosť a zdroje chýb

Hoci teoretický model stereo videnia poskytuje exaktné matematické výsledky, v reálnych robotických aplikáciách je presnosť výpočtu hĺbky limitovaná viacerými fyzikálnymi a algoritmičnými faktormi. Prvým zásadným limitom je samotná vzdialenosť objektu. Z rovnice pre výpočet hĺbky vyplýva, že chyba merania nelineárne narastá so vzdialenosťou. Disparita sa v digitálnych obrazoch meria v pixeloch, čo znamená, že posun o jeden pixel pri blízkych objektoch predstavuje zmenu reálnej vzdialenosti

o niekoľko milimetrov. Pri veľmi vzdialených objektoch, kde je disparita malá, však odchýlka o ten istý jeden pixel môže znamenať chybu niekoľkých centimetrov [9].

Ďalším kritickým faktorom je textúra snímanej scény a svetelné podmienky prostredia. Keďže algoritmy na výpočet disparity (napríklad SGBM) spoliehajú na hľadanie vizuálnej zhody blokov, zlyhávajú pri jednoliatych povrchoch, akými sú čisté biele steny, alebo pri husto sa opakujúcich vzoroch. Rovnako problematické sú odlesky a zrkadlové povrchy, ktoré sa v ľavom a pravom obraze javia z rôznych uhlov odlišne. V takýchto prípadoch algoritmus nedokáže spoľahlivo priradiť korešpondujúce body, čo vedie k vzniku výrazného šumu a tzv. čiernych dier v hĺbkovej mape [6].

Z hľadiska hardvéru je presnosť priamo úmerná kvalite prvotnej kalibrácie. Aj minimálna mechanická odchýlka kamier spôsobí, že transformačné matice prestanú presne zodpovedať realite, čím sa naruší rektifikácia a epipolárne línie sa posunú. Pri manipulácii s objektmi na krátke vzdialenosti navyše do hry vstupuje problém oklúzie. Vzhľadom na existenciu základne vznikajú v tesnej blízkosti robota a na okrajoch objektov oblasti, ktoré vidí iba jedna kamera. Pre tieto slepé uhly nie je možné disparitu vôbec vypočítať [9].

Kapitola 3

Detekcia a lokalizácia objektov

Získanie hĺbkovej mapy pomocou stereo videnia poskytuje robotovi informácie o geometrii okolitého prostredia. Pre úspešnú interakciu a manipuláciu s predmetmi to však nepostačuje. Systém musí byť schopný v zachytenom obraze autonómne identifikovať záujmový objekt a určiť jeho presnú polohu. Tento proces sa v kognitívnej robotike delí na dva kroky: detekciu (rozpoznanie objektu v 2D obraze) a následnú 3D lokalizáciu (priradenie priestorových súradníc nájdenému objektu).

3.1 Farebná segmentácia

Digitálne kamery štandardne snímajú obraz vo farebnom modeli RGB (Red, Green, Blue). Tento model je síce prirodzený pre zobrazovacie zariadenia, pre úlohy počítačového videnia je však vysoko nevhodný. Hlavným problémom RGB priestoru je fakt, že farebná informácia (chrominancia) je úzko spojená s intenzitou osvetlenia (luminanciou). Aj drobná zmena okolitých svetelných podmienok alebo vznik tieňa spôsobí drastickú zmenu hodnôt všetkých troch zložiek, čo vedie k okamžitému zlyhaniu detekčných algoritmov [18].

Tento problém sa v praxi rieši transformáciou pôvodného obrazu do farebného priestoru HSV (Hue, Saturation, Value). Model HSV oddeľuje samotnú farbu (Hue) od jej sýtosti (Saturation) a jasú (Value). Vďaka tejto transformácii je systém schopný definovať farbu hľadaného objektu iba pomocou zložky H, zatiaľ čo zložky S a V poskytujú toleranciu voči premenlivému osvetleniu a tieňom v reálnom laboratórnom prostredí [18, 2].

Po transformácii do priestoru HSV nasleduje proces prahovania (thresholding). Pri prahovaní sa zadefinujú spodné a horné hranice pre každú z troch zložiek, ktoré reprezentujú hľadaný objekt. Napríklad pri detekcii červenej kocky, zložka H (farba) pokrýva špecifické spektrum červenej, hranice pre zložky S a V zabezpečia odfiltrovanie príliš vyblednutých alebo tmavých pixelov. Algoritmus následne prejde každý pixel obrazu.

Ak hodnoty pixelu spadajú do tohto definovaného intervalu, pixel si zachová svoju informáciu (zafarbí sa nabiele). V opačnom prípade je potlačený (zafarbí sa načierne) [2].

Výsledkom tohto procesu je binárna maska. Ide o čiernobiely obraz, v ktorom biele plochy presne reprezentujú izolovaný záujmový objekt. Zvyšok scény tvorí čierne pozadie. Táto maska následne slúži na výpočet kontúr a určenie presného geometrického stredu objektu v 2D rovine [2].

3.2 Rozpoznávanie objektu podľa tvaru

V reálnych podmienkach s premenlivým osvetlením alebo pri výskyte iných objektov s podobnou farbou často nie je farebná segmentácia dostatočne robustná. Doplnenie systému o analýzu geometrického tvaru objektu výrazne zvyšuje spoľahlivosť celého systému. [18]

3.2.1 Detekcia a analýza kontúr

Kontúra predstavuje spojitú čiaru ohraničujúcu skupinu pixelov s rovnakou intenzitou. Detekcia týchto kontúr predstavuje základný algoritmus rozpoznávania tvarov v obraze. Pre každý nájdený uzavretý tvar môžeme vypočítať jeho geometrické vlastnosti, ako sú plocha, obvod a následne hodnotu vyjadrujúcu mieru podobnosti útvaru s ideálnym kruhom – cirkularitu. Cirkularita blízka 1 indikuje takmer dokonalý kruh, čo nám umožňuje odfiltrovať nežiaduce šumy a nepravidelné tvary, ktoré prešli farebným filtrom. [8]

3.2.2 Houghova transformácia pre kružnice

Pokročilejšou metódou v počítačovom videní je Houghova transformácia (Hough Circle Transform). Na rozdiel od analýzy kontúr nevyžaduje táto metóda bezchybnú binárnu masku. Algoritmus pracuje na princípe hlasovania v parametrickom priestore, kde hľadá lokálne maximá prislúchajúce rovnici kružnice:

$$(x - a)^2 + (y - b)^2 = r^2,$$

kde súradnice (a, b) predstavujú stred kružnice a r vyjadruje jej polomer [5]. Táto metóda je obzvlášť vhodná pri detekcii objektov s lesklým povrchom (napríklad hliníková fólia), kde môžu odlesky svetla spôsobiť, že sa farebná maska rozpadá na viacero menších častí. Kombináciou prahovania a Houghovej transformácie sa lokalizujú presné súradnice cieľových objektov s vysokou presnosťou aj v zhoršených vizuálnych podmienkach.

3.3 Alternatívne metódy detekcie objektov

V súčasnom počítačovom videní dominujú pri detekcii objektov prístupy založené na hlbokom učení, konkrétne konvolučné neurónové siete (CNN). Medzi najmodernejšie a najpoužívannejšie architektúry patrí systém YOLO (You Only Look Once). Na rozdiel od farebnej segmentácie, ktorá filtruje obraz výhradne na základe hodnôt pixelov, modely ako YOLO dokážu z obrazu extrahovať zložité priestorové a tvarové príznaky. Vďaka tomu dokážu spoľahlivo identifikovať a klasifikovať objekty aj pri ich čiastočnom prekrytí, deformácii alebo pri drastických zmenách osvetlenia [13].

Nasadenie modelov hlbokého učenia poskytuje vynikajúce výsledky v komplexných prostrediach, no vyžaduje si rozsiahle tréningové datasety a na rozbehnutie modelu v reálnom čase je spravidla nevyhnutná prítomnosť vysokovýkonnej grafickej karty. Na druhej strane, klasické algoritmy počítačového videnia, akou je segmentácia v HSV priestore, nevyžadujú žiadnu fázu tréningu a sú algoritmicky aj pamäťovo mimoriadne nenáročné. Vďaka tomu dokážu bez problémov a rýchlo bežať aj na štandardných procesoroch, avšak za cenu toho, že ich detekčná presnosť klesá pri vizuálne členitých objektoch a v slabo kontrolovaných svetelných podmienkach.

3.4 Lokalizácia v 3D priestore

Finálnym krokom procesu vnímania je transformácia 2D informácie o polohe objektu na jeho 3D súradnice v priestore. Tento proces priamo prepája výsledky detekcie s hĺbkovou mapou vypočítanou v predchádzajúcej kapitole. Prvým krokom je určenie geometrického stredu (ťažiska) detegovaného objektu v binárnej maske. Na tento účel sa v knižnici OpenCV využívajú obrazové momenty, ktoré umožňujú vypočítať súradnice $[u, v]$ reprezentujúce stred pixelovej plochy objektu [2].

Po získaní 2D súradníc stredu objektu v ľavom rektifikovanom obraze systém pristúpi k odčítaniu zodpovedajúcej hodnoty z hĺbkovej mapy. Keďže reálne hĺbkové mapy môžu trpieť šumom alebo výpadkami dát v dôsledku oklúzií, v praxi sa namiesto hodnoty z jediného pixelu často využíva priemerná hĺbka vypočítaná z malého okolia (napr. okno 5×5 pixelov) okolo ťažiska. Tým sa dosiahne vyššia robustnosť voči lokálnym chybám merania.

Na získanie úplnej priestorovej informácie v súradnicovom systéme kamery $[X, Y, Z]$ využívame inverznú projekciu založenú na intrinsických parametroch kamery zistených počas kalibrácie. Súradnica Z (vzdialenosť od kamery) je priamo určená hĺbkovou mapou. Súradnice X a Y sa následne dopyčítajú podľa nasledujúcich vzťahov [9]:

$$X = \frac{(u - c_x) \cdot Z}{f_x}, \quad Y = \frac{(v - c_y) \cdot Z}{f_y} \quad (3.1)$$

Kde $[c_x, c_y]$ je optický stred snímača a f_x, f_y sú zložky ohniskovej vzdialenosti vyjadrené v pixeloch. Výsledný vektor $[X, Y, Z]$ definuje presnú polohu objektu voči optickému stredu kamery. Pre potreby robota je tento vektor následne transformovaný zo súradnicového systému kamery do bazového súradnicového systému robota (zvyčajne umiestneného v jeho základni alebo hrudi), čo umožňuje plánovanie pohybu a následnú manipuláciu s objektom.

Kapitola 4

Inverzná kinematika

V predchádzajúcich kapitolách sme popísali proces získavania priestorových dát, na konci ktorého systém presne pozná 3D súradnice cieľového objektu voči svojmu bázo-
vému súradnicovému systému. Aby však robot mohol s týmto objektom fyzicky inte-
ragovať, musí vedieť preložiť túto priestorovú požiadavku do reálneho pohybu svojich
mechanických manipulátorov. Tento transformačný krok rieši matematický aparát ki-
nematiky nazývaný inverzná kinematika [16].

Pred samotným výpočtom polohy je nevyhnutné definovať fyzickú štruktúru mani-
pulátora. Z mechanického hľadiska ide o otvorený kinematický reťazec, ktorý sa skladá
z pevných článkov (links) pospájaných pohyblivými kĺbmi (joints). Každý nezávislý
pohyb kĺbu, väčšinou ide o rotačný pohyb poháňaný servomotorom, pridáva systému
jeden stupeň voľnosti (DoF z angl. Degrees of Freedom).

Na to, aby koncový efektor dokázal dosiahnuť ľubovoľný bod v 3D priestore a
zároveň v ňom zaujať ľubovoľnú uhlovú orientáciu, potrebuje robot matematicky presne
šesť stupňov voľnosti. Tri slúžia na transláciu (posun po osiach X, Y, Z) a tri na rotáciu
(náklon okolo týchto osí). Ak má robot menej ako šesť kĺbov, jeho možnosti manipulácie
sú obmedzené. Naopak, systémy s viac ako šiestimi kĺbmi (ako napríklad ľudská ruka,
ktorá má 7 DoF) sa označujú ako redundantné. Pri takýchto manipulátoroch existuje
pre jeden cieľový bod nekonečne veľa riešení inverznej kinematiky, čo umožňuje systému
napríklad obchádzať prekážky bez toho, aby zmenil polohu samotného efektora [16].

4.1 Definícia a princíp

Kinematika manipulátorov študuje pohyb robota z čisto geometrického hľadiska, bez
uvažovania síl a dynamiky, ktoré tento pohyb fyzicky spôsobujú. V robotike rozlišujeme
dva základné kinematické prístupy, ktoré sú navzájom opačné: doprednú a inverznú
kinematiku [4].

Dopredná kinematika (Forward Kinematics) rieši úlohu určenia presnej po-

lohy a orientácie koncového efektora v 3D priestore, ak sú známe aktuálne uhly natočenia alebo posuny všetkých jeho kĺbov. Matematicky ide o priamočiary a jednoznačný problém, ktorý sa zvyčajne rieši postupným násobením homogénnych transformačných matic, definujúcich vzťahy medzi jednotlivými článkami manipulátora. Ak poznáme stav všetkých kĺbových premenných $\theta_1, \theta_2, \dots, \theta_n$, vieme úplne jednoznačne vypočítať výslednú priestorovú polohu koncového bodu $[X, Y, Z]$ [4].

Inverzná kinematika (Inverse Kinematics, IK) rieši presne opačný problém, ktorý je však matematicky výrazne zložitejší. Vstupom do výpočtu je požadovaná cieľová poloha (bod) a orientácia koncového efektora v priestore. Výstupom musí byť súbor kĺbových premenných $\theta_1, \dots, \theta_n$, ktoré je nutné na motoroch nastaviť tak, aby sa koncový efektor dostal presne na tieto súradnice [16].

Tento proces je v praxi náročný z troch hlavných dôvodov [4, 16]:

- **Nelinearita rovníc** – Rovnice popisujúce kinematický reťazec obsahujú zložité goniometrické funkcie, čo znamená, že medzi polohou v priestore a natočením kĺbov neexistuje priama lineárna závislosť.
- **Nejednoznačnosť riešenia** – Kým dopredná kinematika má pre dané uhly vždy len jedno riešenie, inverzná kinematika môže mať pre jeden cieľový bod v priestore viacero platných riešení (robot môže k objektu pristúpiť zhora, z boku...). Na druhej strane môže nastať aj situácia, že riešenie vôbec neexistuje, ak sa cieľový bod nachádza fyzicky mimo dosahu robotického manipulátora.
- **Kinematické singularity** – V pracovnom priestore robota existujú špecifické konfigurácie, v ktorých dochádza k strate jedného alebo viacerých stupňov voľnosti. V týchto bodoch manipulátor stráca schopnosť pohybu v určitom smere, čo pri matematickom výpočte inverznej kinematiky vedie k chybám, ako je napríklad delenie nulou. Typickým príkladom je singularita na hranici pracovného priestoru, kedy robot úplne vystrie svoje rameno a koncový efektor sa už fyzicky nedokáže posunúť v smere natiahnutia. Iným bežným prípadom je zápäšná singularita, kedy sa osi dvoch rotačných kĺbov zaraďujú do jednej priamky. V tom momente rotácia oboch kĺbov spôsobuje identický pohyb efektora, jeden stupeň voľnosti zaniká a matematický model nedokáže jednoznačne určiť, ktorým motorom má systém pootočiť [4].

4.2 Analytické vs. numerické metódy

Z hľadiska algoritmického prístupu sa metódy výpočtu inverznej kinematiky rozdeľujú do dvoch hlavných kategórií: analytické (exaktné) a numerické (iteratívne) metódy.

Voľba vhodného prístupu závisí primárne od mechanickej konštrukcie manipulátora a od požiadaviek na výpočtový výkon v reálnom čase [16].

4.2.1 Analytické metódy

Analytický prístup, nazývaný aj riešenie v uzavretom tvare (closed-form solution), hľadá presný matematický vzorec. Do tohto vzorca sa priamo dosadia cieľové priestorové súradnice a výsledkom sú konkrétne požadované uhly jednotlivých kĺbov. Využívajú sa pri tom algebraické a geometrické techniky. Obrovskou výhodou analytického riešenia je jeho extrémna výpočtová rýchlosť a schopnosť presne nájsť všetky možné konfigurácie kĺbov pre daný cieľový bod.

Zásadnou nevýhodou však je fakt, že analytické riešenie neexistuje pre každý typ robota. Podľa Pieperovho pravidla je možné exaktné riešenie nájsť len pre manipulátory so šiestimi stupňami voľnosti, ktoré spĺňajú špecifické konštrukčné podmienky, najčastejšie ide o prítomnosť tzv. sférického zápästia, pri ktorom sa osi posledných troch rotačných kĺbov pretínajú v jednom spoločnom priestorovom bode [4].

4.2.2 Numerické metódy

Ak robot nespĺňa konštrukčné podmienky pre analytické riešenie, alebo ak ide o redundantný systém s viac ako šiestimi kĺbmi, využívajú sa numerické metódy. Tieto algoritmy neposkytujú presný vzorec, ale hľadajú riešenie postupným približovaním, iterovaním.

Proces výpočtu zvyčajne začína v aktuálnej polohe robota, pričom sa vypočíta rozdiel (odchýlku) medzi aktuálnou a cieľovou polohou koncového efektora. Pomocou matematického aparátu nazývaného Jakobián, čo je matica parciálnych derivácií, algoritmus zistí, ktorým smerom a o aký uhol treba pohnúť jednotlivými kĺbmi, aby sa táto odchýlka zmenšila. Tento krok sa v cykle opakuje, až kým sa koncový efektor nedostane k cieľu so splnenou požadovanou toleranciou [3].

Hlavnou výhodou numerických metód je ich univerzálnosť, keďže fungujú nezávisle od kinematickej štruktúry robota. Sú však výpočtovo oveľa náročnejšie na procesor a sú náchylné na uviaznutie v lokálnych minimách. To sú situácie, kedy algoritmus predčasne ukončí hľadanie bez toho, aby našiel skutočné riešenie, hoci po fyzickej stránke na daný cieľ robot dosiahnuť vie [3, 16].

V súčasnej modernej robotike, obzvlášť pri komplexných alebo redundantných manipulátoroch, sa čisté analytické riešenia z konštrukčných dôvodov často nedajú aplikovať. Z tohto dôvodu sa pokročilé riadiace systémy spoliehajú predovšetkým na optimalizované numerické riešenia. Tieto algoritmy dokážu na pozadí iteratívne prepočítavať inverznú kinematiku a plynule naviesť koncový efektor priamo na 3D súradnice detegovaného predmetu.

4.3 Aplikácia v humanoidných robotoch

Implementácia inverznej kinematiky do humanoidných robotov prináša v porovnaní so štandardnými priemyselnými manipulátormi špecifické výzvy. Hlavným dôvodom je, že tieto systémy sú navrhnuté tak, aby anatomicky a kinematicky napodobňovali ľudské telo. Tento dizajn si vyžaduje komplexnejší matematický prístup, ktorý musí okrem samotného dosiahnutia cieľovej polohy zohľadňovať aj celkové držanie tela a prirodzenosť pohybu.

Pri riadení humanoidných paží sa stretávame s niekoľkými kinematickými špecifikami [16]:

- **Kinematická redundancia** – Robotické ekvivalenty ľudskej paže zvyčajne disponujú siedmimi stupňami voľnosti (tri v ramene, jeden v lakti a tri v zápästí). Keďže na plnú priestorovú lokalizáciu koncového efektora postačuje šesť stupňov voľnosti, jeden stupeň je navyše. Táto redundancia vytvára tzv. nulový priestor. V praxi to znamená, že robot dokáže fixovať svoju ruku na jednom mieste v priestore, pričom jeho lakeť môže stále vykonávať kruhový pohyb. Algoritmy inverznej kinematiky musia tento „nadbytočný“ pohyb neustále kontrolovať a optimalizovať.
- **Optimalizácia prirodzeného pohybu** – Pretože pre redundantný manipulátor existuje nekonečne veľa platných kĺbových konfigurácií pre ten istý cieľový bod, numerický algoritmus musí vybrať to najvhodnejšie riešenie. Do výpočtov sa preto zavádzajú sekundárne úlohy (optimalizačné kritériá). Algoritmus sa napríklad snaží minimalizovať celkovú spotrebu energie motorov, vyhnúť sa singularitám, alebo udržať lakeť v takej polohe, ktorá pripomína prirodzené držanie ľudskej ruky.
- **Predchádzanie kolíziám** – Na rozdiel od stacionárnych ramien majú humanoidné roboty objemné telo. Inverzná kinematika musí byť úzko prepojená s geometrickým modelom robota, aby vypočítané trajektórie a uhly neviedli k situácii, že robot pri pokuse o uchopenie predmetu narazí vlastnou pažou do svojej hrude alebo hlavy.
- **Prísne limity kĺbov** – Mechanické kĺby humanoidov majú často asymetrické a striktné uhlové obmedzenia, ktoré verne kopírujú ľudskú anatómiu, napríklad lakeť sa dokáže ohnúť iba v jednom smere. Výpočet inverznej kinematiky musí pri iteráciách tieto limity prísne rešpektovať, inak by došlo k matematickej požiadavke o pohyb, ktorý by fyzicky poškodil robota.

Vzhľadom na túto zložitosť sa pri humanoidných platformách analytické riešenia spravidla nahrádzajú robustnými numerickými riešeniami. Tieto algoritmy fungujú na

princípe inverzie Jakobiánu, zjednodušene povedané, matematicky „obrátia“ model dopredného pohybu robota. Vďaka tomu dokáže systém spätne vypočítať, akým smerom a o aký uhol musí pootočiť každý jeden kĺb, aby sa efektor priblížil k cieľu. [3].

Kapitola 5

Robotické platformy

Presun teoretických modelov počítačového videnia a kinematiky do fyzického sveta si vyžaduje adekvátny hardvér. Robotické platformy v súčasnosti neslúžia len ako nástroje priemyselnej automatizácie, ale predovšetkým ako hlavné výskumné prostriedky, ktoré nám pomáhajú spájať čistú matematiku a reálnu fyziku. V tejto kapitole detailne predstavíme vybrané robotické systémy, ktoré reprezentujú odlišné prístupy k vnímaniu a manipulácii.

5.1 Robot NICO

Humanoidný robot NICO (Neuro-Inspired COmpanion) je pokročilý robotický systém, ktorý bol primárne vyvinutý výskumnou skupinou Knowledge Technology na Univerzite v Hamburgu. Platforma je určená predovšetkým pre potreby výskumu v oblasti kognitívnej robotiky a multimodálnej interakcie medzi človekom a robotom [10].

Z hľadiska fyzických rozmerov je NICO navrhnutý tak, aby svojou hardvérovou stavbou a kinematikou pripomínal dieťa vo veku troch až štyroch rokov. Na rozdiel od masívnych komerčných humanoidov je konštruovaný z otvorených hardvérových komponentov, predovšetkým z inteligentných servomotorov série Dynamixel, a zo súčiastok vyrobených technológiou 3D tlače. Tento prístup zaručuje platforme vysokú hardvérovú flexibilitu a prispôsobiteľnosť [10].

5.1.1 Vizuálny senzorický systém

Hlava robota, ktorej dizajn bol voľne inšpirovaný otvoreným projektom iCub, je prispôbená pre pokročilé stereoskopické videnie. Vo svojich očných jamkách je NICO vybavený dvojicou RGB kamier s prekrývajúcim sa zorným poľom. Toto hardvérové usporiadanie verne napodobňuje ľudské binokulárne videnie. Vďaka prekrývaniu obrazov dokáže systém vizuálneho spracovania extrahovať mapu disparít a následne presne vypočítavať 3D súradnice objektov v pracovnom priestore robota [10].

5.1.2 Kinematická štruktúra

Z hľadiska pohybu predstavuje NICO komplexný kinematický reťazec. Jeho paže sú navrhnuté tak, aby v rámci konštrukčných možností replikovali rozsah pohybov ľudskej končatiny. Každé rameno disponuje viacerými stupňami voľnosti. Napríklad samotný ramenný kĺb využíva tri stupne voľnosti na simuláciu funkcie guľového kĺbu, čo ramenu poskytuje široký priestorový dosah.

Tieto anatomické vlastnosti si však vyžadujú nasadenie pokročilých kinematických modelov. Vzhľadom na mechanické limity kĺbov a prítomnosť objemného tela musí riadiaci systém robota, ktorý štandardne komunikuje prostredníctvom operačného systému ROS (Robot Operating System), neustále spracovávať kolízne modely a využívať optimalizované numerické algoritmy inverznej kinematiky na zaistenie bezpečného a plynulého pohybu efektorov [10].

5.2 Robotické rameno Niryo Ned

Druhou hardvérovou platformou, ktorá dopĺňa našu experimentálnu zostavu, je kolaboratívne robotické rameno Niryo Ned. Tento systém, vyvinutý francúzskou spoločnosťou Niryo, je navrhnutý ako otvorená platforma pre výskum, vzdelávanie a prototypovanie aplikácií. Na rozdiel od robota NICO predstavuje Niryo Ned klasickú architektúru priemyselného manipulátora prispôbenú pre laboratórne podmienky [12].

5.2.1 Hardvérová a softvérová architektúra

Základom výpočtovej a riadiacej jednotky robota je integrovaný mikropočítač Raspberry Pi 4 v kombinácii s mikrokontrolérom pre riadenie motorov na nízkej úrovni. Pohyb jednotlivých kĺbov je zabezpečený kombináciou krokových motorov a servomotorov, čo garantuje stabilnú presnosť a plynulosť pohybu. Zásadnou výhodou tejto platformy je jej natívna softvérová kompatibilita s ekosystémom ROS a rámcami pre počítačové videnie a strojové učenie. Platforma je konštrukčne pripravená na integráciu externých vizuálnych modulov, čo priamo podporuje aplikáciu algoritmov na detekciu a priestorovú lokalizáciu objektov [12].

5.2.2 Kinematické vlastnosti a pracovný priestor

Z kinematického hľadiska ide o sériový manipulátor s presne šiestimi stupňami voľnosti, čo predstavuje zaužívaný priemyselný štandard pre plnohodnotnú priestorovú manipuláciu. Táto konfigurácia umožňuje koncovému gripu dosiahnuť akýkoľvek bod v definovanom pracovnom priestore a zároveň k nemu pristúpiť pod ľubovoľným uhlom.

V porovnaní s redundantnou štruktúrou humanoida NICO je kinematika ramena Niryo Ned deterministickejšia. Vďaka presne šiestim osiam je systém vhodným kandidátom nielen pre pokročilé numerické metódy, ale za určitých okolností aj pre analytické metódy inverznej kinematiky, bez nutnosti riešiť nulový priestor alebo sa vyhýbať vlastnému telu [12].

5.3 Koordinácia rozdielnych platforiem

Spojenie dvoch hardvérovo a kinematicky odlišných systémov – do jedného spolupracujúceho celku predstavuje komplexnú inžiniersku výzvu. Tento prístup, známy ako heterogénna multirobotická koordinácia, si vyžaduje robustnú softvérovú architektúru schopnú premostiť rozdiely v ich nízkoúrovňovom riadení a zabezpečiť bezproblémovú výmenu dát v reálnom čase [11].

5.3.1 Spoločný komunikačný rámec

Kľúčovým prvkom pre dosiahnutie vzájomnej spolupráce medzi týmito platformami je využitie operačného systému ROS ako spoločného middlewaru. ROS vytvára univerzálne rozhranie pre špecifický hardvér každého robota a umožňuje im komunikovať prostredníctvom štandardizovaných správ (topics a services). Vďaka tomu dokáže vizuálny systém robota NICO plynule odosielať spracované priestorové dáta do distribuovaného riadiaceho uzla, ktorý následne môže generovať pohybové príkazy aj pre rameno Niryo Ned, čím oba stroje fungujú ako jeden integrovaný systém [11].

5.3.2 Transformácia súradnicových systémov

Najväčšou výzvou pri koordinácii viacerých nezávislých platforiem je zjednotenie ich priestorového vnímania. Každý robot operuje vo vlastnom lokálnom súradnicovom systéme. Ak kamerový systém v hlave NICO deteguje objekt na súradniciach $[X, Y, Z]$, tieto hodnoty sú platné výhradne voči jeho vlastnému telu.

Aby mohlo kolaboratívne rameno s týmto objektom fyzicky manipulovať, musia byť tieto súradnice matematicky prepočítané pomocou homogénnych transformačných matíc do jeho vlastného súradnicového systému. V prostredí ROS sa na túto úlohu využíva štandardizovaná knižnica TF (Transform Library), ktorá v reálnom čase udržiava a prepočítava priestorové vzťahy (translácie a rotácie) medzi všetkými článkami oboch robotov a ich spoločným pracovným prostredím [11].

Týmto zjednotením vnímania a pohybu vzniká robustný teoretický aj technologický základ pre realizáciu praktických experimentov, v ktorých sa spája vizuálny potenciál kamerových systémov s fyzickou manipuláciou v 3D priestore.

Kapitola 6

Cieľ práce

Hlavným cieľom práce je návrh, implementácia a následné overenie systému spolupráce humanoidného robota NICO a robotickej ruky Niryo Ned. NICO prostredníctvom stereoskopického videnia deteguje a následne pomocou algoritmov inverznej kinematiky fyzicky dosahuje pohybujúci sa objekt držaný ramenom Niryo Ned. Súčasťou cieľa je aj návrh a integrácia externého detekčného systému na báze mikrokontroléra Arduino, ktorý bude slúžiť na detekciu fyzického dotyku.

Čiastkové ciele

Na úspešné dosiahnutie celkového cieľa je nutné splnenie niekoľkých menších krokov:

1. **Vizuálna detekcia a lokalizácia:** Vytvoriť softvérový program v prostredí ROS, ktorý pomocou farebnej segmentácie a hĺbkovej mapy dokáže identifikovať 3D súradnice loptičky v priestore.
2. **Implementácia inverznej kinematiky:** Navrhnuť a optimalizovať numerický výpočet inverznej kinematiky pre ruku robota NICO, ktorý umožní plynulý pohyb koncového efektora na detegované súradnice loptičky.
3. **Konštrukcia externého detekčného obvodu:** Navrhnuť a zostaviť obvod s využitím mikrokontroléra Arduino, ktorý na základe uzavretia elektrického kontaktu zachytí moment fyzického dotyku (vodivý povrch loptičky a prsta robota).
4. **Koordinácia a riadenie pohybu:** Zabezpečiť synchronizáciu medzi ramenom Niryo Ned, ktoré vykonáva náhodný pohyb s objektom, a robotom NICO, ktorý na tento pohyb reaguje.
5. **Experimentálne overenie** Výslednú implementáciu overiť viacerými meraniami, ktoré nám fyzicky dokážu presnú lokalizáciu a následný výpočet výslednej konfi-

kurácie ruky robota NICO dotykom s objektom. Tento dotyk bude zaznamenaný správnym zapojením elektrického Arduino obvodu.

Kapitola 7

Metodika práce a implementácia systému

7.1 Charakteristika laboratórneho pracoviska

Pre realizáciu experimentu sme navrhli pracovisko, kde hlavnú úlohu zohráva humanoidný robot NICO. Tento robot je pevne umiestnený na jednej strane pracovného stola. Oproti nemu sa nachádza robotické rameno Niryo Ned. NICO disponuje dvomi robotickými pažami, ktoré sú zakončené štvorprstými rukami. Každá ruka má síce v dlani integrovaný senzor, no jeho citlivosť a umiestnenie neboli pre náš experiment postačujúce.

Rameno Niryo Ned drží vo svojom uchopovači tyčku, na ktorej je napevno uchytená flórbalová loptička s priemerom 7 cm. Takéto priestorové rozloženie zabezpečuje, že sa loptička nachádza v spoločnom pracovnom priestore oboch robotov, vďaka čomu ju NICO dokáže vizuálne zamerať a následne sa jej fyzicky dotknúť.

7.2 Spracovanie obrazu a priestorová lokalizácia

Pre úspešnú interakciu robota NICO s cieľovou loptičkou bude prvým krokom zistenie jej polohy v priestore. Tento proces sme rozdelili do troch krokov – stereoskopická kalibrácia, detekcia guľatého tvaru v obraze a výpočet 3D súradníc.

7.2.1 Stereoskopická kalibrácia

Oči robota NICO, čiže kamery integrované v jeho hlave, sú vybavené širokouhlými šošovkami typu rybie oko (fisheye). Takéto kamery vykazujú výrazné skreslenie, čo by pre štandardný model dierkovej komory viedlo k nepresným výsledkom. Z tohoto dôvodu sme využili špeciálny modul `cv2.fisheye` z knižnice OpenCV.

Využili sme kalibračnú metódu pomocou šachovnicového vzoru nasnímaného v rôznych polohách. Najskôr sme pre každú kameru individuálne určili vnútorné parametre a koeficienty skreslenia. Modul fisheye z knižnice je veľmi citlivý na dáta, preto sme maticu vnútorných parametrov odhadli pomocou štandardnej funkcie `cv2.calibrateCamera`. Tento odhad sme potom použili ako vstup pre presnú kalibráciu rybieho oka:

```
cv2.fisheye.calibrate
```

Následne sme vykonali stereoskopickú kalibráciu oboch kamier súčasne, ktorá nám vrátila rotačnú maticu (R) a translačný vektor (T). Pri tomto výpočte sme vnútorné parametre oboch kamier zafixovali (`cv2.fisheye.CALIB_FIX_INTRINSIC`), aby sa optimalizoval výlučne priestorový vzťah medzi nimi.

```
cv2.fisheye.stereoCalibrate
```

Získané rotačné a translačné matice popisujú presnú geometriu nášho stereoskopického systému. Kvôli extrémnemu skresleniu a širokému zornému uhlu sme však nemohli použiť štandardnú funkciu `cv2.stereoRectify`. Projekčné matice P_1, P_2 a reprojekčnú maticu Q sme zostavili manuálne. Matica Q bola vypočítaná s využitím ohniskovej vzdialenosti (f_x), optických stredov (c_x, c_y) a horizontálnej bázy kamier (T_x), čo umožňuje presný prepočet 2D súradníc a disparity na priestorovú hĺbku.

Pre správny výpočet rektifikačných máp, sme sa rozhodli otestovať dva odlišné prístupy k spracovaniu získanej rotačnej matice R . Prvým prístupom je štandardné matematické rozdelenie rotácie na dve polovice pomocou Rodriguesovej transformácie, čo by malo teoreticky zabezpečiť symetrické natočenie oboch kamier. Druhou alternatívou je zjednodušený model s využitím jednotkovej matice (`R_empty`), ktorý vplyv rotácie pri procese generovania máp zanedbáva.

Oba tieto prístupy nám poskytnú potrebné samostatné rotačné matice oboch kamier, vďaka ktorým nám funkcia `cv2.fisheye.initUndistortRectifyMap` vygeneruje rektifikačné mapy. Cieľom tohto porovnania je určiť, ktorý z prístupov poskytuje v našich špecifických laboratórnych podmienkach vyššiu stabilitu a presnosť pri následnom odhade priestorovej hĺbky.

7.2.2 Detekcia objektu na základe tvaru a jasu

Vzhľadom na to, že cieľová loptička bola obalená v hliníkovej fólii, klasická farebná segmentácia by pre nepravidelné odlesky zlyhávala. Preto sme sa rozhodli detegovať loptičku na základe jej tvaru a intenzity jasu.

Zachytený vstupný obraz z oboch kamier sme najskôr transformovali do odtieňov sivej a aplikovali Gaussov filter. Robili sme tak hlavne preto, aby sme znížili výpočtovú náročnosť. Farebný obraz z kamery má 3 farebné kanály, ale po transformácii má len

1, ktorý reprezentuje intenzitu svetla. Gaussov filter nám odstráni digitálny šum, čo nám obraz jemne rozmaze. Vďaka rozmazanému obrazu sme schopní zachytiť aj povrch našej loptičky, ktorá vďaka hliníkovej fólii nie je dokonale guľatá.

```
gray = cv2.cvtColor(frame, cv2.COLOR_BGR2GRAY)
blur = cv2.GaussianBlur(gray, (19, 19), 0)
```

Na takto vyhladený obraz sme použili `cv2.Canny`, čím sme získali binárnu mapu hrán. Následne sme aplikovali Houghovu transformáciu (`cv2.HoughCircles`), ktorá v mape hrán identifikovala všetky potenciálne kruhy v predurčenom rozsahu polomerov – 10 až 30 pixelov.

Keďže algoritmus mohol v obraze nájsť viacero kruhových tvarov ako napríklad kĺby robotov, je nutné z nájdenných útvarov nájsť cieľovú loptičku. Pre každý detegovaný kruh sme vytvorili masku a vypočítali priemerný jas. Kruh s najvyšším jasom sme označili ako loptičku, keďže hliníková fólia výrazne odráža dopadajúce svetlo.

7.2.3 Triangulácia

Po úspešnej lokalizácii stredových bodov loptičky v ľavom (l_x, l_y) a pravom (r_x, r_y) obraze nasledoval výpočet priestorových súradníc. Najskôr sme vypočítali rozdiel x-ových súradníc v oboch obrazoch $(l_x - r_x)$, čo označujeme ako horizontálnu disparitu.

Pomocou funkcie `cv2.perspectiveTransform` a reprojekčnej matice Q sme boli v tomto momente schopní transformovať súradnice z 2D obrazu na reálne 3D súradnice X, Y, Z . Tieto súradnice však vyjadrujú polohu objektu z pohľadu optického stredu kamier. Aby mohol robot NICO presne vypočítať konfiguráciu jeho robotickej paže pre dosiahnutie loptičky, transformovali sme súradnice do hlavného súradnicového systému robota. To sme dosiahli aplikáciou pevne daných offsetov a inverziou znamienok podľa samotných orientácie nášho robota.

7.3 Riadenie pohybu ramena Niryo Ned

Robotické rameno Niryo Ned slúži na dynamické overenie navrhnutého algoritmu pre robota NICO. Jeho hlavnou úlohou je nepravidelne meniť pozíciu držanej loptičky tak, aby ju bol NICO schopný detegovať a následne dosiahnuť.

Ovládanie ramena sme zabezpečili pomocou knižnice `pyniryo`, ktorá umožňuje priame riadenie ramena prostredníctvom IP protokolu. Samotná logika pohybu je implementovaná v naprogramovanej triede `NiryoRandomController`, ktorá nám bola poskytnutá vedúcim bakalárskej práce. Tento ovládač zabezpečuje spojenie, kalibráciu a generovanie bezpečných trajektórií pohybu.

Program pracuje výlučne s kĺbmi robota a pevne definovanými softvérovými limitmi pre každý zo šiestich stupňov voľnosti. Hlavnou funkciou riadenia je metóda `random_movement`, ktorá pri každom zavolaní vygeneruje náhodnú odchýlku od súčasnej pozície ramena:

```
def _sample_joint_target(self):
    raw_target = []
    for center, delta in zip(self.START_JOINTS, self.JOINT_DELTAS):
        raw_target.append(center + random.uniform(-delta, delta))
    return self._clamp_joints(raw_target)
```

Vygenerované uhly sú následne zvalidované, či spĺňajú nastavené limity `JOINT_LIMITS`. Po úspešnej kontrole sú uhly odoslané do riadiacej jednotky ramena. Po dosiahnutí vygenerovanej cieľovej pozície rameno signalizuje ukončenie pohybu pípnutím a zostane v aktuálnej polohe, až kým mu nedôjde nový pokyn.

7.4 Inverzná kinematika a pohyb robota NICO

Po získaní 3D súradníc loptičky v priestore sme schopní vypočítať presné uhly jednotlivých kĺbov ľavej robotickej paže robota NICO. Každému kĺbu bol priradený unikátny identifikátor (ID) pre jednoduchšiu a efektívnejšiu prácu s robotom. V rámci nášho experimentu nás zaujímajú kĺby ID22, ID2, ID4 a ID6, ktoré predstavujú postačujúce 4 stupne voľnosti pre dosiahnutie ktoréhokoľvek bodu v pracovnom priestore robota. Robotická paža má aj ďalšie 2 použiteľné kĺby v oblasti zápästia, ktoré sme sa pre ich nepresnosť rozhodli nepoužiť.

Pri výbere vhodného algoritmu na výpočet samotnej kinematiky zohral hlavnú úlohu fakt, že nemáme k dispozícii presne definovaný matematický model robota s milimetrovou presnosťou všetkých offsetov medzi hlavou, krkom, trupom či rukou. Práve preto sme sa rozhodli implementovať kombinovaný algoritmus s analytickým odhadom a numerickou optimalizáciou, čím dokážeme nepresnosti odstrániť.

7.4.1 Geometrická transformácia a počiatočný odhad

Súradnice loptičky sú v tomto bode pretransformované do hlavného súradnicového systému robota. Preto prvým krokom bude pretransformovať ich do lokálneho systému základne ľavej paže, ktorá sa nachádza v ramene (kĺb ID22). Transformácia počíta s nami nameranými fyzickými rozmermi hlavy, krku, trupu a ruky robota, čo znamená, že vykazujú drobné odchýlky od skutočných hodnôt.

Ďalej sme implementovali funkciu na výpočet počiatočného analytického odhadu konfigurácie kĺbov. Pomocou trigonometrie, ktorá zanedbáva niektoré konštrukčné ofsety paže, funkcia vypočíta približné uhly na interakciu paže s loptičkou. Tento odhad slúži ako štartovacia konfigurácia pre náš numerický algoritmus optimalizácie, čím sme zvýšili rýchlosť výpočtu a pravdepodobnosť úspešnej interakcie.

7.4.2 Dopredná kinematika

Model doprednej kinematiky bol implementovaný ako pomocná funkcia na optimalizáciu výslednej konfigurácie. Využili sme pri tom reťazenie homogénnych transformačných matíc, ktoré počítajú teoretickú polohu koncového efektora pri aktuálnych uhloch jednotlivých kĺbov. Model počíta aj s dĺžkami jednotlivých článkov paže a ofsetmi ramena. Matematika je realizovaná pomocou knižnice NumPy, čo zabezpečuje vysokú výpočtovú efektivitu pri stovkách iterácií, ktoré optimalizačný algoritmus vykonáva.

7.4.3 Nelineárna optimalizácia a penalizačná funkcia

Keďže konštrukčné ofsety znemožnili nájdenie presných analytických riešení v uzavretom tvare, inverznú kinematiku riešime pomocou nelineárnej optimalizácie. Konkrétne sme sa rozhodli využiť algoritmus L-BFGS-B, ktorý minimalizuje tzv. nákladovú funkciu (cost function). Táto funkcia vypočíta euklidovskú vzdialenosť medzi vypočítanou polohou koncového efektora ramena robota a skutočnou polohou loptičky.

Nákladová funkcia udeľuje trestné hodnoty konfiguráciám, ktoré zvolili uhly kĺbov blízko hardvérových limitov kĺbov. Algoritmus počíta aj s možnosťou, že uviazne v lokálnom minime. Aby sme tomu zabránili, inicializujeme výpočet z rôznych počiatočných konfigurácií. Výsledná konfigurácia bude konfigurácia s najmenšou odchýlkou a zároveň menšou, ako je nami určená tolerancia. Toleranciu si predurčujeme, aby sme vedeli určiť, kedy detegovaný bod nie je v dosahu robotickej ruky nášho robota.

7.4.4 Fyzická realizácia pohybu

Nasledujúci krok premení teoretickú matematiku nášho algoritmu na reálny fyzický pohyb robotickej paže. Servomotory radu Dynamixel, ktoré má NICO integrované vo svojej paži, sú zapojené do sériovej zbernice a komunikujú prostredníctvom verzie 1.0 s prenosovou rýchlosťou 1 000 000 bps.

Na samotný zápis do hardvérových registrov sme využili knižnicu `dynamixel_sdk`, ktorá sprostredkuje komunikáciu so servomotormi. Celý tento proces je zapuzdrený v triede `DXL`, poskytnutej vedúcim práce pre účely tejto práce. Trieda zabezpečuje otváranie portov, priradzovanie komunikačných paketov a implementuje ochranné funkcie chrániace hardvér pred poškodením.

Prepojenie medzi naším výpočtom inverznej kinematiky a fyzickým riadením zabezpečuje metóda `move_to_deg`. Vstupom tejto metódy je identifikačné číslo (ID) cieľového kľbu a požadovaný uhol natočenia v stupňoch:

```
def move_to_deg(self, dxl_id: int, goal_deg: float) -> bool:
    raw = deg_to_raw(goal_deg)
    return self.move_to_raw(dxl_id, raw)
```

Vnútoraná logika servomotorov Dynamixel nepracuje so stupňami, preto musí metóda najskôr prepočítať uhol na celočíselnú hodnotu (tzv. raw hodnotu v rozsahu 0 až 4095), ktorá zodpovedá konkrétnemu tiku optického enkodéra motora. Prepočítaná hodnota je následne bezpečne zapísaná do príslušného pamäťového registra motora (`ADDR_GOAL_POSITION`).

Súčasťou triedy DXL sú aj metódy kontrolujúce limity, ako napríklad obmedzenie maximálnej rýchlosti pohybu. Toto obmedzenie zabraňuje prudkým trhnutiam ramena a zaisťuje plynulý pohyb. Podobne je implementovaná aj metóda na limity jednotlivých kľbov, aby nedošlo ku nadmernému pootočeniu jedného z kľbov a následnému poškodeniu hardvéru.

7.5 Hardvérová implementácia a detekcia fyzického kontaktu

Keďže nami využívaná verzia robota NICO nedisponuje vhodnými senzormi dotyku na prstoch, rozhodli sme sa tento problém vyriešiť návrhom vlastného elektrického obvodu pomocou mikrokontroléra Arduino UNO. Princíp detekcie spočíva v jednoduchom uzavretí obvodu pri fyzickom kontakte.

7.5.1 Fyzické zapojenie obvodu

Jedna vetva tohto obvodu vedie pozdĺž ľavej paže robota NICO a je zakončená vodičom, ktorý sme obmotali priamo okolo jeho prsta. Cieľovú loptičku sme obalili do hliníkovej fólie, čím sme na nej vytvorili vodivý povrch. Z tohto povrchu vedie druhá vetva obvodu pozdĺž ramena Niryo Ned priamo k Arduinu, kde je zapojená na zem (GND). V momente, keď sa prst robota dotkne alobalovej loptičky, elektrický obvod sa uzavrie. Mikrokontrolér tento stav okamžite zaznamená a vyhodnotí ho ako úspešný dotyk.

7.5.2 Spracovanie signálu v mikrokontroléri

Aby Arduino dokázalo tento stav vyhodnotiť, na vstupnom digitálnom pine sme programovo aktivovali interný pull-up rezistor (`INPUT_PULLUP`). V pokojovom stave tak pin zaznamenáva logickú jednotku (`HIGH`). Pri fyzickom kontakte robota s loptičkou sa napätie stiahne na úroveň zeme, čiže na logickú nulu (`LOW`).

Pri fyzickom kontakte dvoch kovov obvod nezopne okamžite a čisto. Namiesto toho signál na zlomok sekundy „poskakuje“, čo by Arduino mohlo prečítať ako desiatky rýchlych dotykov za sebou. Aby sme tomuto falošnému čítaniu zabránili, implementovali sme do Arduino jednoduchý časový filter (tzv. debouncing). Ten funguje tak, že po zachytení prvého dotyku počká 30 milisekúnd na ustálenie signálu. Ak je dotyk po tomto čase stabilný, Arduino ho potvrdí a odošle do počítača správu `CONTACT` alebo `RELEASE` spolu s presným časom udalosti.

7.5.3 Spracovanie a validácia kontaktu

Arduino už implementovanú logiku má, následne bolo potrebné navrhnuť systém, ktorý bude počúvať a zapisovať do súboru. Výsledný program sa napojí na Arduino a každú prijatú správu o kontakte alebo o prerušení kontaktu, zapíše do logovacieho súboru `button_log.csv` spolu s presným časom prijatia. Následne program pomocou `flush()` vynúti okamžitý zápis na disk, čo nám dovoľuje tento kontakt zachytiť v reálnom čase pri kontrole dotyku.

Pre automatizované vyhodnotenie dotyku robota loptičky, slúži funkcia `valid_last_contact`. Po tom, ako robot NICO dokončí svoj vypočítaný pohyb smerom k loptičke, systém načíta CSV záznam a overí, či v určenom časovom okne (napríklad v intervale posledných 5 sekúnd) skutočne nastal kontakt:

```
def valid_last_contact(seconds):
    contact = get_last_contact()
    if contact is None:
        return False

    contactTime = datetime.fromisoformat(contact["pc_timestamp_iso"])
    currTime = datetime.now()
    diff = (currTime - contactTime).total_seconds()

    return diff <= seconds
```

Tento prístup umožňuje celému systému bežať úplne autonómne. Systém po dokončení pohybu vyhodnotí platnosť dotyku a následne vydá pokyn ramenu Niryo Ned na presun loptičky do novej, náhodne vygenerovanej polohy pre ďalšiu interakciu.

7.6 Synchronizácia procesov

Implementáciu všetkých procesov bolo nutné pri testovaní zosynchronizovať do jedného riadiaceho programu (`main.py`). Program sme navrhli tak, aby správne nakonfiguroval a nakalibroval robotické systémy, zosúladiť všetky implementované triedy a metódy, ktoré následne vykonávajú svoju úlohu v danom čase.

7.6.1 Inicializačná fáza

Program začína sériou inicializačných krokov, ktoré pripravujú experimentálne prostredie:

- **Inicializácia hardvéru:** Nadviaže sa komunikácia so zbernicou servomotorov Dynamixel a paža robota NICO sa presunie do bezpečnej východiskovej polohy.
- **Pripojenie pomocného robota:** Inicializuje sa riadiaca trieda pre rameno Niryo Ned, prebehne sieťové spojenie a hardvérová kalibrácia ramena.
- **Kalibrácia videnia:** Načítajú sa vopred vypočítané parametre stereoskopického videnia (vnútorné parametre kamier a reprojekčná matica Q).
- **Aktivácia senzorov:** Spustí sa asynchrónne snímanie obrazu z oboch kamier umiestnených v hlave robota NICO.

7.6.2 Logika hlavného cyklu

Po inicializácii program spúšťa hlavný cyklus, ktorý opakovane realizuje autonómny experiment vo fázach:

1. **Presun cieľovej loptičky:** Program vydá pokyn ramenu Niryo Ned na vykonanie náhodného pohybu, čím sa loptička premiestni do novej polohy v priestore.
2. **Vizuálna lokalizácia:** Systém zosníma aktuálne obrazy z kamier a vyhľadá v nich stredové súradnice loptičky. Ak je objekt úspešne detegovaný v oboch pohľadoch, vypočítajú sa reálne súradnice loptičky v priestore.
3. **Kinematika a pohyb:** Získané súradnice slúžia ako vstup pre výpočet inverznej kinematiky prostredníctvom metódy `inverse_kinematics`. Ak je nájdená konfigurácia uhlov validná, príkazy sa postupne odošlú servomotorom a robot vykoná pohyb.
4. **Validácia kontaktu:** Po dokončení pohybu program skontroluje logy z mikrokontroléra Arduino. Systém automaticky vyhodnotí úspešnosť dotyku a pokus zapíše.

Tento cyklus je navrhnutý tak, aby dokázal autonómne spracovať aj neúspešné pokusy o detekciu či kontakt. Náhodný pohyb ramena Niryo Ned môže loptičku presunúť do oblasti, ktorá je pre pažu robota NICO nedosiahnuteľná, rovnako môže byť loptička v danej polohe nedetegovaná z dôvodu silných odleskov svetla. V týchto prípadoch program aktuálny pokus preruší a vráti sa do začiatkovej polohy. Hneď nato je iterácia spustená znovu bez nášho zásahu.

V prípade, že v logovacom súbore nie je nájdený zápis o kontakte pri danom pokuse, aktuálna iterácia nekončí, ale začína iteratívne meniť cieľové súradnice. Kvôli veľkému skresleniu našich šošoviek v očiach robota NICO, v niektorých prípadoch dochádza k nepresnej kalibrácii, a teda aj detekcii cieľového bodu. Z tohto dôvodu sa program v rámci aktuálnej iterácie snaží o jemnú úpravu cieľových súradníc a zopakovanie pohybu.

7.7 Metodika testovania

Po implementácii a prepojení všetkých hardvérových a softvérových modulov bolo potrebné overiť spoľahlivosť celého systému v reálnych laboratórnych podmienkach. Pre získanie relevantných výsledkov sme navrhli plne autonómny experimentálny cyklus riadený vyššie spomínaným hlavným programom.

Samotné testovanie pozostávalo zo série 50 po sebe nasledujúcich iterácií. Počas celého priebehu experimentu sme pre každú iteráciu do logovacích súborov zaznamenávali dáta o úspešnosti vizuálnej detekcie, presnosti kinematického riešiča a úspešnosti fyzického kontaktu.

Tento zautomatizovaný prístup eliminoval vplyv ľudského faktora počas meraní a umožnil nám zozbierať objektívny súbor dát. Tieto dáta slúžia ako hlavný podklad pre záverečné štatistické zhodnotenie výkonnosti a presnosti navrhnutého robotického systému.

Kapitola 8

Výsledky práce a diskusia

Na záver nám už zostáva iba finálne vyhodnotenie úspešnosti celého systému. Dáta sme zozbierali podľa metodiky v kapitole 7, pričom séria 50 testovacích iterácií trvala 30 minút. Výsledky sme analyzovali z troch hlavných hľadísk, a to úspešnosti vizuálnej detekcie, dosiahnuteľnosti a celkovej úspešnosti fyzického kontaktu.

8.1 Vyhodnotenie vizuálnej detekcie a triangulácie

Prvým krokom v každej iterácii bolo nájdenie loptičky v obraze z oboch kamier a výpočet jej 3D súradníc. Z celkového počtu 50 vygenerovaných polôh dokázal algoritmus úspešne vypočítať priestorové súradnice v 43 prípadoch, čo predstavuje 86 % úspešnosť.

V 7 prípadoch (14 %) algoritmus vizuálnej detekcie zlyhal a iterácia bola bezpečne prerušená. Na základe analýzy výstupných logov sme zistili, že príčiny týchto zlyhaní boli dve, a to falošná detekcia loptičky a žiadna detekcia.

Falošná detekcia nastala v 6 zo 7 prípadov. V týchto prípadoch jedna z kamier úspešne detegovala a lokalizovala cieľovú loptičku, avšak druhá kamera kvôli silným odleskom a silnému zaobleniu šošovky detegovala iný falošný kruhový objekt. Takýto prípad bol identifikovaný vďaka väčšiemu rozdielu vypočítaných stredových bodov objektov, a bol vyhodnotený ako chybná detekcia.

Absencia objektu, ktorá nastala len v jednom prípade z 50, znamená, že jedna alebo obe kamery neboli schopné cieľov loptičku detegovať vôbec. Bolo to zapríčinené umiestnením objektu v vysoko zaoblenej časti obrazu a následnej nepresnej rektifikácii obrazu.

Naše výsledky potvrdzujú vysokú presnosť navrhnutého systému a taktiež odolnosť voči falošným pohybom. Z hľadiska bezpečnosti je pre nás podstatný fakt, že robot nevykoná kolízny pohyb pri neistých dátach.

8.2 Inverzná kinematika a ochrana pracovného priestoru

Z 43 úspešne triangulovaných bodov bolo 6 bodov vyhodnotených pri výpočte inverznej kinematiky ako nedosiahnuteľné. Predstavuje to 14 % prípadov z úspešne detegovaných objektov, a 12 % zo všetkých 50 iterácií.

Tento stav nepredstavuje chybu algoritmu, ale naopak, potvrdzuje jeho správne fungovanie. Robotické rameno Niryo Ned pohybuje loptičku náhodne, čo znamená jej občasný presun na okraj pracovného priestoru, prípadne do inej fyzicky nedosiahnuteľnej polohy robota NICO. Pod touto polohou rozumieme polohou, ktorá by vyžadovala prekročenie hárđverových limitov kĺbov paže. Algoritmus tento stav ale detegoval a pohyb bezpečne zrušil, čím sme predišli poškodeniu jednotlivých servomotorov robota NICO.

8.3 Úspešnosť fyzického kontaktu a adaptívne ladenie

Zvyšných 37 iterácií predstavovalo prípady, kedy bola loptička úspešne lokalizovaná a zároveň ležala v dosahu paže robota. Vo všetkých 37 prípadoch systém nakoniec zaznamenal úspešný fyzický kontakt s loptičkou, čím sme dosiahli 100 % úspešnosť.

Zaujímavejším zistením experimentu bola analýza toho, na koľký pokus v danej iterácii kontakt reálne nastal. Pre extrémne skreslenie šošoviek vykazovala vykazovali vypočítané súradnice Z miernu odchýlku. Túto nepresnosť náš program riešil adaptívnym iteračným upravovaním cieľového bodu. Rozdelenie úspešnosti podľa počtu pokusov sme zaznamenali do tabuľky 8.1

Tabuľka 8.1: Úspešnosť fyzického kontaktu v závislosti od počtu iteračných korekcií

Poradie pokusu	Počet korekcií	Počet kontaktov	Podiel (%)
1. pokus	0	20	54,1
2. pokus	1	10	27,0
3. pokus	2	2	5,4
4. pokus	3	4	10,8
5. pokus	4	1	2,7
Spolu		37	100,0

8.4 Zhodnotenie experimentu

Získané dáta nám potvrdzujú nevyhnutnosť iteratívneho doľadovania polohy cieľového objektu. Pokiaľ by sme toto doľadovanie zanedbali a pre každú polohu vypočítali inverznú kinematiku len raz, úspešnosť experimentu by dosiahla len 40 %, čiže 20 z 50 testov.

Práve vďaka externému overovaniu kontaktu cez mikrokontrolér Arduino a implementácii iteratívnej úpravy hĺbky celková úspešnosť dosiahla 74 %. Tento výsledok považujeme za daných podmienok za úspech. Program preukázal stabilitu, odolnosť voči šumu v obraze a bezpečnosť pri riadení hardvéru.

Literatúra

- [1] Minoru Asada, Kevin J., Kuniyoshi Yasuo, Giorgio Metta, and Giulio Sandini. Cognitive developmental robotics: A survey. *IEEE Transactions on Autonomous Mental Development*, 1(1):12–34, 2009.
- [2] Gary Bradski and Adrian Kaehler. *Learning OpenCV: Computer Vision with the OpenCV Library*. O’Reilly Media, 2008.
- [3] Samuel R. Buss. Introduction to inverse kinematics with jacobian transpose, pseudoinverse and damped least squares methods. *IEEE Journal of Robotics and Automation*, 17(1-19), 2004.
- [4] John J. Craig. *Introduction to Robotics: Mechanics and Control*. Pearson, New York, 4th edition, 2018.
- [5] Richard O. Duda and Peter E. Hart. Use of the hough transformation to detect lines and curves in pictures. *Communications of the ACM*, 15(1):11–15, 1972.
- [6] David A. Forsyth and Jean Ponce. *Computer Vision: A Modern Approach*. Pearson, 2011.
- [7] Farkaš I. Gäde C. Gavura J., Vavrecka M. Robotic calibration based on haptic feedback improves sim-to-real transfer. In *International Conference on Artificial Neural Networks (ICANN)*. Springer Nature, 2025.
- [8] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing*. Pearson, 4 edition, 2018.
- [9] Richard Hartley and Andrew Zisserman. *Multiple View Geometry in Computer Vision*. Cambridge University Press, 2004.
- [10] Matthias Kerzel, Erik Strahl, Sven Magg, Nicolaos Tsagarakis, and Stefan Wermter. NICO – Neuro-inspired companion: A developmental humanoid robot platform for multimodal interaction. In *26th IEEE International Symposium on Robot and Human Interactive Communication (RO-MAN)*, pages 113–120. IEEE, 2017.

- [11] Anis Koubaa. *Robot Operating System (ROS): The Complete Reference*, volume 2. Springer, Cham, Switzerland, 2017.
- [12] Niryo SAS. *Niryo Ned - User Manual and Technical Specifications*. Niryo SAS, Wambrechies, France, 2021.
- [13] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.
- [14] Agnieszka Sciutti, Francesco Rea, Giulio Sandini, and Cristina Becchio. Investigating the ability to read others’ intentions using humanoid robots. *Frontiers in Psychology – Cognitive Science*, 6(1362):1–10, 2015.
- [15] Bruno Siciliano and Oussama Khatib. *Springer Handbook of Robotics*. Springer, 2016.
- [16] Bruno Siciliano, Lorenzo Sciavicco, Luigi Villani, and Giuseppe Oriolo. *Robotics: Modelling, Planning and Control*. Springer, London, 2009.
- [17] R. Skoviera, K. Stepanova, M. Tesar, G. Sejnova, J. Sedlar, M. Vavrecka, R. Babuska, and J. Sivic. Teaching robots to imitate a human with no on-teacher sensors. what are the key challenges? *arXiv preprint arXiv:1901.08335*, 2019.
- [18] Richard Szeliski. *Computer Vision: Algorithms and Applications*. Springer, 2nd edition, 2022.
- [19] David Vernon. *Artificial Cognitive Systems: A Primer*. MIT Press, 2014.
- [20] Zhengyou Zhang. Microsoft Kinect sensor and its effect. *IEEE Multimedia*, 19(2):4–10, 2012.

Príloha A: obsah elektronickej prílohy

V elektronickej prílohe priloženej k práci sa nachádza zdrojový kód programu a súbory s výsledkami experimentov. Zdrojový kód je zverejnený aj na stránke <http://mojadresa.com/>.

Ak uznáte za vhodné, môžete tu aj podrobnejšie rozpísať obsah tejto prílohy, prípadne poskytnúť návod na inštaláciu programu. Alternatívou je tieto informácie zahrnúť do samotnej prílohy, alebo ich uviesť na oboch miestach.

Príloha B: Používateľská príručka

V tejto prílohe uvádzame používateľskú príručku k nášmu softvéru. Tu by ďalej pokračoval text príručky. V práci nie je potrebné uvádzať používateľskú príručku, pokiaľ je používanie softvéru intuitívne alebo ak výsledkom práce nie je ucelený softvér určený pre používateľov.

V prílohách môžete uviesť aj ďalšie materiály, ktoré by mohli pôsobiť rušivo v hlavnom texte, ako napríklad rozsiahle tabuľky a podobne. Materiály, ktoré sú príliš dlhé na ich tlač, odovzdajte len v elektronickej prílohe.